

Deciphering the Invisible Vote: An Exploration of Evaluation Bias and Rule Fairness

摘要 (Summary)

Dancing with the Stars uses a dual evaluation scheme: judges' technical scores (meritocracy) and audience votes (popularity). While this design increases suspense, it can also invite fairness concerns when the two components are unevenly weighted. Because vote counts are confidential and therefore latent, we model the dynamics of fan support to illuminate this "black box" and to identify a principled trade-off between technical excellence and public preference.

针对粉丝投票不可观测的难题, 本文首先构建了一个部分可观测动态系统 (Partially Observable Dynamic System) 对选手潜在得票份额进行建模, 并采用粒子滤波 (Particle Filtering) 算法进行数值求解。该方法在预测任务中实现了 79.19% 的 Top-3 准确率和 37.92% 的 Top-1 准确率; 在后验回测中, 模型成功重现了 82.20% 的历史淘汰事件, 展现了极高的历史还原度。为了衡量确定性, 我们构建了基于得票份额标准差的置信区间。被淘汰选手的得票估计确定性显著高于幸存选手, 同时随着赛程推进, 整体得票份额的确定性呈现递减趋势。

进而, 我们采用反事实分析 (Counterfactual Analysis) 框架推演了规则变更后的潜在结果, 发现不同规则下的结果存在差异。Rank Rule 和 Percentage Rule 产生相同结果的概率仅为 38.2%。为了分析不同规则的倾向性, 我们构建了统计指标来量化规则倾向性。计算结果显示, Percentage Rule 更倾向于粉丝。这是因为 Rank Rule 通过“封顶效应”限制了粉丝的影响力。

为了分析争议案例, 我们构建了 Robbed Score 和 Fan-Carried Score 两类量化指标来衡量技术分高但是被淘汰、技术分低但是最终排名高这两种争议事件, 并精准识别了题目中提到的四位争议选手。我们选取了最有争议性的选手们进行数据分析, 发现对于技术分高但是粉丝量不多的选手, 使用 Percentage Rule 会使其预期排名平均下降 0.32, 相比之下, Judge Save 机制则为此类易跌入末位区间的技术型选手提供了关键的修正机会。最终, 我们综合考虑各个规则对粉丝和评委的倾向性, 最终推荐 Rank + Judge Save 的规则。

为了量化各因素的影响权重, 我们建立了混合线性模型体系。结果显示, 专业舞伴 (Pro Partner) 的影响微乎其微, 比赛结果更多由明星自身特质主导。演员是赛场上最具

竞争力的群体，获得了更高的观众投票与评审打分。同时，数据揭示了明显的偏好分化：粉丝热衷于投票给政治家，而评委则更认可真人秀明星和音乐家的表现。

最后，基于量化指标，我们构建了 Adaptive Concave Diminishing-returns Weighted Bottom-3 System，该方法在评委和观众的分歧大的时候调高评委评分的权重，从而允许节目在制造极具观赏性的“意见冲突”与“戏剧张力”的同时，确保竞技结果的专业底线不被突破。**关键词 (Keywords):** 粒子滤波方法，隐变量推断，Counterfactual

Inference，线性混合模型

目录

1	Introduction	4
1.1	问题重述	4
1.2	文献综述	4
1.3	Our Work	5
2	Preparation for Modelling	5
2.1	Assumption and Justification	5
2.2	数据预处理	5
2.3	Notation	6
3	任务一	7
3.1	问题思路	7
3.2	模型构建与求解	8
3.3	模型准确性	12
3.4	模型确定性与不确定性异质性分析	13
4	任务二	15
4.1	问题分析	15
4.2	规则比较与选择	15
4.3	争议分析	17
4.4	规则推荐	20
5	5. 任务三	22
5.1	5.1 问题分析	22
5.2	5.2 建模	22
5.3	结果分析：评价体系的异质性 (Heterogeneity)	24
6	6. 任务 4	25
6.1	ACDW-B3 模型构建	25
6.2	模型评判	26
6.3	制作方建议 (Producer's Memo)	26
7	灵敏度分析	26
	参考文献	27

1 Introduction

1.1 问题重述

在全球综艺娱乐市场中，竞技类真人秀融合专业性和观赏性，拥有广泛的观众基础。《与星共舞》作为这一领域的代表性节目，核心模式是专业舞者和名人搭档，源自英国节目《舞动奇迹》，在全球数十个国家播出，影响力遍布全球。该节目的评分体系由专家评审打分与粉丝投票两部分的融合结果决定每周的淘汰人选，需在竞技公平性与节目观赏性中进行权衡。

本研究以《与星共舞》美国版第 1-34 季的选手信息、评审分数及比赛结果等数据为基础，聚焦评分机制优化与影响因素量化两大核心目标，通过数学建模与数据分析完成以下任务：

任务 1：构建数学模型估计每位选手各参赛周的粉丝投票数。解决模型一致性与估计确定性两大问题，需构建一致性衡量指标，并设计可量化的确定性度量指标。

任务 2：结合估计的粉丝投票数，对比排名合并法和百分比合并法的应用效果，识别方法对粉丝投票的偏向程度。重点聚焦评审与粉丝存在分歧的争议性名人选手，分析采用两种合并方法是否会导致这些选手的比赛结果产生变化，同时探讨第 28 季改变的规则，让评审投票从倒数两对选手中选择淘汰对象，是否影响比赛结果。最后根据分析结果，进行多维度分析，选择推荐方法。

任务 3：基于包含估计粉丝投票数的数据，构建模型分析专业舞者特征以及名人个体特征对比赛结果的影响。量化这些因素的影响程度差异，并对比它们对评审分数与粉丝投票的影响方式是否存在差异。

任务 4：基于前述分析，设计一套兼具专业公平性和节目观赏性的投票评分合并系统，详细论证该系统的合理性，以说服节目制作方采纳该方法。

1.2 文献综述

许多学者都曾研究过评分投票合并机制优化问题。Carlos Molinero, Elsa Arcaute, Duncan Smith, Michael Batty 通过分层聚类 and 空间网络分析得出单一合并方法可能会导致特定地区观众的声音被压制。Cynthia Dwork*, Moritz Hardt 等作者进行相似性度量和公平约束优化，得出可以动态调整二者的合并权重的自适应权重机制。Amanda Aird, Cassidy All 和其他作者研究双阶段合并机制，结合社会选择理论，构建多代理 (Multi-Agent) 的灵活架构。Alan Collins, Jordi McKenzie 等作者通过构建计量经济学模型和统计分析，得出专业评审本身可能存在的“顺序偏差”的结论。

1.3 Our Work

2 Preparation for Modelling

2.1 Assumption and Justification

Assumption 1. 公众记忆的马尔可夫性，即当周的粉丝热度主要取决于上一周的热度保留和当周的表现，而不直接依赖于更久远的历史。

Justification. 社交媒体与节目播出节奏快，观众对选手的印象更新周期较短，常以周为单位。多数观众不会主动回顾所关注的选手几周前的表现，而是基于本期最新观感和上一周的记忆来决定本期是否关注该名选手和是否为其投票。

Assumption 2. 存在评审引导效应 (Judges' Influence)，评审的分数会对粉丝投票产生引导作用，具体表现为同情分、从众效应等现象。本文假设这种影响是以线性的叠加的形式纳入投票生成机制。

Justification. 该节目评审的专业点评及分数公布通常先于粉丝投票环节，会对粉丝投票产生引导。其次，采用线性叠加形式既能精准捕捉核心影响机制，又能兼顾模型的可解释性，避免过度复杂的非线性设定。

Assumption 3. 淘汰结果是唯一真值 (Elimination as Sole Ground Truth)，由于真实的粉丝票数从未公开，我们假设“被淘汰者必然是总分最低者（或最低之一）”是唯一的硬约束条件。

Justification. 从赛事运营逻辑来看，商业选秀节目需维持基本的规则公平性与观众信任度。为保障节目传播力和公信力，其淘汰机制本质上必须以选手综合表现所对应的量化得分为核心依据。

2.2 数据预处理

我们对原始数据集进行了数据预处理，主要包括缺失值处理、特征编码及评分标准化。

2.2.1 数据清洗与缺失值填充

原始数据在字段完整性和格式上存在一定差异，我们采取了以下处理策略：

缺失值处理：对于“选手年龄”字段，缺失值统一填充为中位数 30；“家乡国家”缺失时设为“Unknown”；若“最终名次”缺失则进行标记。

淘汰周逻辑解析：从 results 字段中提取关键信息。仅当包含“Week X”模式时判定为被淘汰；对于主动退赛 (Withdrew) 的情况，因其不属于比赛竞技结果，不计入淘汰事件。

评审分精简：针对数据中存在的“N/A”或 0 分情况（通常代表该周末参赛或评委缺席），我们设定仅保留大于 0 的有效分数。选手的每周得分由该周所有有效评审分的算术平均值决定。

2.2.2 特征工程

我们对初始数据进行了热度编码与降维，以便模型计算。最终构建了一个 9 维特征向量。

年龄标准化：为消除量纲影响，对年龄进行标准化处理，计算公式为 $A_{norm} = (Age - 35)/15$ 。

国籍二值化：根据选手是否来自美国，构造布尔特征 I_{US} （美国选手为 1.0，否则为 0.0）。

行业 One-Hot 编码：将选手的职业背景映射为演员、运动员、歌手、电视名人、模特、喜剧演员及其他共 7 个类别。这种编码方式能够有效捕捉不同行业背景对观众投票偏好的潜在影响。

2.2.3 清洗后数据统计

经过清洗，最终获得包含 34 个赛季、共有 421 名选手的有效样本。数据集中记录了 298 次淘汰事件，平均每赛季包含 12.4 名选手。

2.3 Notation

为了清晰地阐述模型，我们将本文使用的主要数学符号定义如下：

表 1: 主要符号说明

符号	说明
$J_{i,t}$	选手 i 在第 t 周获得的评审分数 (Judge Score)
$\pi_{i,t}$	选手 i 在第 t 周的粉丝投票份额 (Fan Vote Share)
$\hat{\pi}_{i,t}$	粉丝投票份额的后验估计 (Posterior estimate)
$S_{i,t}$	第 t 周生存得分 (由规则 R 计算)
R	评分/淘汰规则 (Rule)
$E_{real,t}$	第 t 周真实淘汰集合 (Ground truth)
$Alignment_{Fan}(R)$	规则 R 的粉丝一致性得分
$Alignment_{Judge}(R)$	规则 R 的评审一致性得分
$Score(R)$	规则 R 的综合评分 (任务二用于推荐)
S_1, S_2	争议指标: 民粹指数/遗珠指数 (Populist/Robbed)
$Y_{i,t}^J, Y_{i,t}^F$	任务三混合效应模型因变量 (评审/粉丝)
X_{Traits}	选手特征向量 (年龄、行业、周次等)
$\beta^J, \beta^{F1}, \beta^{F2}$	任务三固定效应系数
u_{Pro}, u_{Star}	职业舞者/明星的随机截距 (Random intercepts)
ICC_{Pro}	职业舞者随机效应方差贡献率 (ICC)
$f_{i,t}$	任务四: 凹变换后的投票效用 (Compressed vote utility)
p	任务四: 效用压缩因子, $p \in (0, 1)$
ρ_t	任务四: 评审与粉丝排名的 Spearman 相关系数
λ_t	任务四: 动态评审权重
w_t^k	粒子滤波中第 t 周第 k 个粒子的权重

3 任务一

3.1 问题思路

首先明确问题类型: 每周的评审打分 $J_{i,t}$ 与最终淘汰结果 $E_{real,t}$ 是已知观测, 真实粉丝投票不可观测。我们需要基于这些已知信息反演每位选手在每周的粉丝投票份额 $\pi_{i,t}$, 因此这是一个隐变量推断 (Latent Variable Inference) 问题。

同时, 一个赛季包含多周比赛, 粉丝投票份额不仅与当周表现有关, 也受到前序周次的影响, 具有明显的时间依赖性; 因此应将其建模为一个动态系统。综合“部分可观测 + 动态演化”的特点, 本问题属于 Partially Observable Dynamic System。

图 1: Problem Approach Flowchart (占位)

Known conditions $\rightarrow$ {Weekly jury scores, Fan votes (unobserved), Final elimination results} $\rightarrow$ The target unknown (Fan vote shares)

图 1: 任务一问题思路流程图 (占位)

3.2 模型构建与求解

3.2.1 人气建模与得票份额计算

首先明确问题的类型。每周的评审分与最终淘汰情况是已知的，我们需要根据这些信息构建数学模型来预测粉丝投票份额。这是一个隐变量推断的问题。

同时一个赛季中有许多周的比赛，粉丝的投票份额不仅与当前周的表现有关，同时也与之前周的表现有关。所以这是一个动态的模型。模型的类型是 Partially Observable Dynamic System.

在明确模型的类型后，建立模型以预测选手的得票份额。我们认为选手的得票份额与选手的长期人气、观众的投票倾向有关。一个选手的长期人气的建模如下：

$$\mu_{i,t} = \mu_{i,t-1} + \kappa \cdot \mathbb{I}(|\tilde{J}| > \delta) \cdot \tilde{J} + \eta_t \quad (1)$$

选手在时间点的长期 $\lambda \equiv \mu_{i,t}$ 为上一时间点的时间 $\lambda \equiv \mu_{i,t-1}$ 加上一个过程噪声 $\eta_t \sim (0, \sigma_\mu)$ ，当 Z-score 标准化后的评委评分 $\tilde{J}$ 的绝对值超过阈值 δ 时，我们将其视为一次“显著事件”（表现显著优异或显著失误）。此时该周表现会对选手的长期人气状态产生一次方向性的冲击： $\tilde{J} > 0$ 表示人气提升， $\tilde{J} < 0$ 表示人气下降；冲击强度与 $|\tilde{J}|$ 成正比。

我们规定 $x_{i,t}$ 为观众在第 t 周对选手 i 的即时投票倾向 (Voting Tendency)。该投票倾向同时受到上一周投票倾向的记忆项、当前长期人气 $\mu_{i,t}$ 以及评委评分 $J_{i,t}$ 的共同影响，其状态转移模型为：

$$x_{i,t} = \rho \cdot x_{i,t-1} + (1 - \rho) \cdot (\mu_{i,t} + \gamma \cdot J_{i,t}) + \varepsilon_t \quad (2)$$

其中 $\rho \in (0, 1)$ 表示投票倾向的记忆保留系数： ρ 越大， $x_{i,t}$ 越依赖上一周的惯性； $(1 - \rho)$ 则控制当周新增信号（即 $\mu_{i,t} + \gamma \cdot J_{i,t}$ ）对 $x_{i,t}$ 的注入强度。参数 γ 刻画评委评分 $J_{i,t}$ 对投票倾向的边际影响。

该设定将长期人气状态 $\mu_{i,t}$ 与当周评分带来的短期扰动同时纳入，从而在同一框架下刻画投票倾向的长期趋势与短期波动。

每个选手的得票份额为：

$$\pi_{i,t} = softmax(x_t) = \frac{exp(x_{i,t})}{\sum_k exp(x_{k,t})} \quad (3)$$

3.2.2 规则分析与生存得分计算

在得到了选手的得票份额后，我们就可以依据规则计算选手得分。赛事规则分为三类核心模式，各阶段规则定义以及计算逻辑如下表所示：

表 2: 规则分析

赛季区间	规则类型	计算逻辑
S1-S2	Rank Rule	评委排名和投票排名直接相加
S3-S27	Percentage Rule	评审分、投票数分别按占比折算后加权求和
S28+	Rank + Judge Save	以排名和为基础，搭配评委拯救机制

为判定选手晋级还是淘汰，定义生存得分作为判定的核心指标，不同规则类型对应差异化的生存得分计算公式。在分数百分比规则中，评审分占比和投票份额两部分的权重构成均为 50%。定义为选手的最终生存得分，为选手的单周评审得分；为选手的当期投票份额。核心计算公式如下：

$$S_i = \left(\frac{J_i}{\sum_k J_k} \right) + \pi_i \quad (4)$$

而在排名规则下，定义 $Rank_{J_i}$ 和 $Rank_{\pi_i}$ 分别为选手的评审分排名和投票份额排名。由于排名越靠前，排名和数值越小，所以排名和为逆指标。因此以负排名和为核心计算变量。同时，在实际比赛中，存在平局判定这一复杂情形。根据节目制作人的官方解释，当总排名积分相同时，观众投票数较低者将被淘汰。为确保模型与官方淘汰逻辑的高度一致性，我们通过在生存得分公式中引入平局破局微扰项引入微干扰项 $\xi \cdot \pi_i$ ，其中 ξ 为微扰系数，用于消除排名完全相同时的判定歧义。

$$S_i = -(Rank_{J_i} + Rank_{\pi_i}) + \xi \cdot \pi_i \quad (5)$$

此外，《与星共舞》有时会出现某周不进行淘汰，而将当周分数与次周分数累加合并判定淘汰的情况。针对此类情形，模型根据不同的规则类型采用了差异化的累加策略：

评委分数累加：在所有赛季中，若第 t 周无淘汰，则第 $t+1$ 周的评审分 $J_{i,t+1}$ 将自动累加前序未结算周的分数：

$$J_{i,accumulated} = \sum_{T \in \text{Non-elimination Window}} J_{i,T} \quad (6)$$

投票份额累加：百分比规则 (S3-S27)：采用份额直接累加。由于规则本质是总分占比与总票数占比之和，因此直接累加选手的投票份额。

排名规则 (S1-2, S28+): 采用积分累加。该规则下累加的是选手的单周排名积分 (如第一名积分), 而非原始投票份额。这种处理方式避免了“单周大比分获胜”带来的红利在积分制下被不当放大, 更符合积分制的竞技本质。

3.2.3 模型求解

为了求解这个模型, 我们选择了粒子滤波 (序贯蒙特卡洛)。对于这一类问题, 一般的做法有回归, Kalman 滤波, Markov Chain Monte Carlo (MCMC), 粒子滤波四种, 它们的比较如下:

表 3: 模型求解方法对比			
Method	Key idea	Main caveat (here)	Fit
Regression	Static mapping.	No dynamics (memory).	Low
Kalman filter	Recursive; linear-Gaussian.	Poor for discrete elimination.	Low
MCMC	Posterior sampling.	Offline; slow for sequential use.	Medium
Particle filter	Sequential; nonlinear.	Compute-heavy.	High

模型求解流程如图:




图 2: 模型求解流程图

首先初始化 1000 个粒子。对于粒子 k ，它有着四个参数 μ_0^k , x_0^k , w_0^k , S_t^k ，分别对应着初始长期人气、初始短期人气，初始权重，初始分数。

对于每一周的每个粒子，运行状态演化方程得到预测的 μ_t^k , x_t^k ，随后计算得票率 $\pi_t^k = \text{softmax}(x_t^k)$ 。

随后进行先验预测，汇总粒子的投票率，得到

$$P(i \text{ is eliminated}) = \sum_k w_k \cdot \mathbb{I}[S = \min(S^k)] \quad (7)$$

接着计算似然值 L_t^k ，更新权重 $\tilde{w}_t^k = w_{t-1}^k L_t^k$ ，并进行归一化处理：

$$w^k = \frac{\tilde{w}^k}{\sum_i \tilde{w}^i} \quad (8)$$

然后对所有的粒子进行重采样，每个粒子被抽到的概率为新的权重 w^k 。

最后进行后验估计：

$$\hat{\pi}_i = \sum_k w^k \cdot \pi_i^k \quad (9)$$

其中似然的计算方法如下。模型要根据数据得到后验的得票份额，如果模型效果好，那么幸存的人的分数应该比淘汰的分数更高。基于这个想法，建立了对应的似然统计量。

a. 基础淘汰似然 - 对应 28 季以前

单人淘汰时的似然函数：

$$L = \prod_{j \in \text{Survivors}} \sigma(\alpha \cdot (S_j^k - S_e^k)) \quad (10)$$

多人淘汰时的似然函数：

$$L = \prod_{e \in \text{Eliminated}} \prod_{s \in \text{Survivors}} \sigma(\alpha \cdot (S_s^k - S_e^k)) \quad (11)$$

其中 α 为判别力参数，其随时间增大而增大，代表比赛后期优胜劣汰界限更分明。

b. 评审拯救似然 - 对应 28 季以后

28 季以后，淘汰是一个两阶段概率事件：首先要落入倒数两名 (Bottom 2)，这取决于 $S_{i,t}$ 。其次是评审裁决 (Judge Decision)，而这取决于技术分。因而似然函数为：

$$L = \underbrace{\left[\prod_{j \in S_{\text{safe}}} \sigma(\alpha \cdot (S_j - \max(S_e, S_s))) \right]}_{\text{Stage 1: Bottom 2 形成概率}} \times \underbrace{\sigma(\beta \cdot (J_s - J_e))}_{\text{Stage 2: 评审拯救概率}} \quad (12)$$

它建模为一个仅与技术分差相关的 Sigmoid 函数，剔除“人气”的影响，以体现“理想评委”假设。

3.3 模型准确性

为了衡量模型的准确性，我们使用了 Top-N 命中率、后验一致概率 (Posterior Consistency Probability)、MAP (MAP Match Rate) 一致率作为指标。后验一致概率和 MAP 一致率衡量了模型训练时的表现，Top-N 命中率衡量了模型在预测时的表现。

后验一致概率衡量了在更新权重后，有多少权重的粒子做出了正确的预测。其表达式为：

$$P_{consistency} = \sum_{k=1}^K w_t^k \cdot \mathbb{I}(\text{Sim}(R, J_t, \pi_t^k) \in E_{real,t}) \quad (13)$$

其中 $E_{real,t}$ 表示这周被淘汰的选手集合， $\text{Sim}(R, J_t, \pi_t^k)$ 表示若该粒子的投票份额 $\pi^{(k)}$ ，评审分 J_t ，比赛规则 R 得到的理论上应该被淘汰的选手。

为了评估模型的还原能力，我们使用了 MAP Match Rate，它本质上代表了模型在整个历史跨度 (S1-S34) 中成功还原历史的经验概率。

$$\text{Average MAP Match Rate} = \frac{1}{T} \sum_{t=1}^T \underbrace{\mathbb{I}(\text{Sim}(R, J_t, \hat{\pi}_t^{MAP}) \in E_{real,t})}_{\text{第 } t \text{ 周是否命中 (0 或 1)}} \quad (14)$$

其中， $\hat{\pi}_t^{MAP}$ 是后验分布的期望值：

$$\hat{\pi}_{i,t}^{MAP} = \mathbb{E}[\pi_{i,t} | D_{1:t}] \approx \sum_{k=1}^K w_t^k \cdot \pi_{i,t}^k \quad (15)$$

为了进一步评估模型对淘汰的预测成功率，我们引入了 Top-N 命中率指标。其计算方法如下：

$$Top - N = \frac{1}{T} \sum_{t=1}^T \mathbb{I}(\text{Rank}_t(E_{real,t}) \leq N) \quad (16)$$

其中 $\text{Rank}_t(E_{real,t})$ 表示第 t 周真实被淘汰的选手的排名。排名根据模型预测的淘汰概率从大到小得出。该指标可以评判我们是否在淘汰实际发生前做出了正确的预测。

经过 4320 组参数的全空间网格搜索 (Grid Search)，识别出了以下几组具有特殊意义的参数配置。

表 4: 参数搜索结果

类别 (Category)	ρ	γ	δ	α
综合最优 (Overall Best)	0.9	0.0	1.2	7.0
最高准度 (Max Accuracy)	0.8	0.7	1.8	7.0
最高精度 (Max Precision)	0.7	0.8	1.8	7.0

综合最优的超参数被采用。其表现如下：

表 5: 模型表现

指标	命中率	随机基线
Top-1	37.92%	~ 10%
Top-3	79.19%	~ 30%

可以看到模型的指标显著高于随机基线，我们的模型是有效的。
同时各赛季的准确率如下：

表 6: 赛季准确率

规则类型	平均命中率
Percentage (S3-S27)	80.40%
Rank (S1-2, S28+)	77.25%

两种规则下表现相当，说明模型对规则的理解是正确的。

3.4 模型确定性与不确定性异质性分析

仅给出点估计 (Point Estimate) 往往不足以全面评估模型的可靠性。得益于粒子滤波 (SMC) 基于蒙特卡洛采样的非参数特性，不仅能获得粉丝投票份额的期望值，还能完整重构出其后验概率密度函数 (PDF)。本节将基于粒子分布构建确定性度量指标，并分析不同比赛状态下的不确定性异质性。

3.4.1 确定性度量指标构建

为了量化估计结果的可信度，基于第周重采样后的粒子集构建统计量。

首先，计算每位选手在第周的加权后验均值 (Weighted Posterior Mean) 作为得票份额的点估计值，其计算方法如下：

$$\hat{\pi}_{i,t} = \mathbb{E}[\pi_{i,t} | \mathcal{D}_{1:t}] \approx \sum_{k=1}^K w_t^{(k)} \cdot \pi_{i,t}^{(k)} \quad (17)$$

其次，计算加权后验标准差 (Weighted Posterior Std) 以衡量分布的离散程度：

$$\sigma_{i,t} = \sqrt{\sum_{k=1}^K w_t^{(k)} \cdot (\pi_{i,t}^{(k)} - \hat{\pi}_{i,t})^2} \quad (18)$$

基于中心极限定理的正态近似假设，构建 95% 置信区间 (95% Confidence Interval, CI)：

$$CI_{i,t} = [\max(0, \hat{\pi}_{i,t} - 1.96\sigma_{i,t}), \min(1, \hat{\pi}_{i,t} + 1.96\sigma_{i,t})] \quad (19)$$

最后，定义置信区间宽度 (CI Width) 作为模型不确定性的核心度量指标：

$$Uncertainty_{i,t} = CI_{i,t}^{upper} - CI_{i,t}^{lower} \quad (20)$$

该指标具有明确的含义。CI Width 越窄，意味着粒子群对该选手得票份额的估计越集中，模型对该推断结果的“确定性”越高；反之则意味着估计存在较大的不确定性。

3.4.2 幸存者与淘汰者的不确定性异质性 (Heterogeneity of Uncertainty)




图 3: 不确定性异质性分析

可以发现一个显著的现象：模型对被淘汰选手的估计确定性显著高于幸存选手。具体而言，被淘汰选手的平均 CI Width 显著小于幸存选手的平均 CI Width。

这可能是因为一名选手的“淘汰”是一个极为严苛的观测事件。它要求该选手的综合生存分 (Score) 必须低于场上所有其他幸存选手。这一条件在似然函数计算中充当了强力的“过滤器”，所有认为该选手“高票”或“中票”的粒子都会被赋予极低的权重甚至被剔除，迫使剩余粒子的分布高度坍缩在“低得票率”的狭窄区间内。因此，模型对淘汰者的状态判定是高度确定的。

同时 Vote Share 的不确定性随着每次比赛的进行都在增加。这是因为随着比赛进行，选手数在变少，从而导致每个选手的 Vote Share 增加。

4 任务二

4.1 问题分析

估计的粉丝投票份额 $\hat{\pi}_{i,t}$, 真实评审分 $J_{i,t}$, 真实淘汰结果是已知的, 我们有以下三个目标。

目标 1: 比较不同规则的结果的差异性。

目标 2: 分析争议选手 (如 Bobby Bones) 在不同规则下的结果。

目标 3: 给出最佳规则。

目标 1 和目标 2 要求我们分析实际不存在的情况, 因而这是一个概率性反事实推演 (Probabilistic Counterfactual Inference) 问题。目标 1 和目标 3 涉及比较不同规则的好坏, 需要构建相应的量化指标。

4.2 规则比较与选择

4.2.1 新规则下的结果计算

任务二要比较新旧规则结果的差异, 这就要求计算新的规则下的选手得票率。使用来自任务一中的后验粒子群进行计算。先使用这些粒子计算每周的选手得票率与生存分 π^k , 再运用新规则 R_{new} 计算选手生存分 S_{new}^k 与选手排名, 最后得到新规则下的淘汰概率与淘汰结果。具体的计算方法与任务一中相同。

在新规则下, 生存分最低的选手被淘汰。同时在新规则下选手的淘汰率为:

$$P(i \in E | R_{new}) = \sum w^k \cdot \mathbb{I}(i \in E^k) \quad (21)$$

4.2.2 规则差异

在得到新规则的结果后, 就可以探究两种规则的结果之间的差异。使用结果一致率来衡量不同规则的淘汰结果的差异。赛季结果一致率计算方法如下:

$$P_t(E_{rank} = E_{pct}) = \sum_{k=1}^K w^k \cdot \mathbb{I}(E_{rank}^k = E_{pct}^k) \quad (22)$$

$$Agreement = \frac{1}{T} \sum_{t=1}^T P_t(E_{rank} = E_{pct}) \quad (23)$$

其中 P_t 是周结果一致率, Agreement 是赛季结果一致性, 计算方法为取每周的周结果一致率的平均值。

接着, 定义粉丝一致性得分, 该值数值越高, 代表粉丝投票对结果影响越大, 计算公式如下:

$$Alignment_{Fan}(R) = \frac{\mathbb{E}_{k \leq K}[Rank_{\pi}(E^k)] - 1}{n_t - 1} \quad (24)$$

其中，期望 $\mathbb{E}_{k \leq K}$ 表示对 K 个粒子的加权平均，而 $n_t - 1$ 是对排名的归一化。该值的取值范围为 0 到 1。在取 0 时，代表规则淘汰了人气第 1 名。在取 1 时，代表规则淘汰了人气最后一名。

最后，计算评审一致性得分，该值数值越高，代表技术分对结果影响越大，计算方法如下：

$$Alignment_{Judge}(R) = \frac{\mathbb{E}_{k \leq K}[Rank_J(E^k)] - 1}{n_t - 1} \quad (25)$$

对 Rank Rule 和 Percentage Rule 的计算如下：




图 4: 规则一致性对比

基于上述数据，有以下关键结论：

规则内秉不一致性 (Inherent Rule Disagreement): 我们的模拟显示，Rank Rule 与 Percentage Rule 的赛季结果一致率仅有 38.2%，即仅有 38.2% 概率产生相同的淘汰结果。

倾向性差异 (Bias Directionality): Percentage Rule 具有显著的亲粉丝倾向 (Pro-Fan Bias): 其 $Align_{Fan}$ 高达 0.945，比 Rank Rule (0.687) 高出 0.38。这是因为百分比制允许超级巨星的海量票仓直接“淹没”技术分的劣势。Rank Rule 具有更高的技术权重 (Pro-Meritocracy): 其 $Align_{Judge}$ 为 0.823，比 Pct Rule (0.781) 高出 5%。序数排名设置了粉丝投票的影响的上限，使得技术分落后的选手更容易跌入危险区。

同时我们在不同的赛季上计算了赛季结果一致率，发现不同赛季的一致性有着明显差别：

S1-S2 (Rank Era): 全局一致率高达 73.2% (选手分化不明显，规则差异被掩盖)。

S3-S27 (Percentage Era): 全局一致率骤降至 28.5%。这说明该时期的赛制极度偏向粉丝，导致了大量不符合 Rank 逻辑的“爆冷”结果。

S28+ (Modern Era): 全局一致率回升至 66.4%。引入 Judge Save 后，赛制重新在技术与人气之间找到了平衡。

4.3 争议分析

4.3.1 指标构建

为了量化什么样的选手的有争议的，需要构建对应的指标。指标需要能够反映“评审意见”与“观众投票”之间的分歧。分歧具体体现在两种情况，分别是评委分高但是被早早淘汰以及评委分低但是取得较好名次。

构建以下两个指标来衡量两种情况是否发生：

表 7: 争议指标定义

维度	名称和解释	典型案例
S1	民粹指数 (Populist Score): 评审认为差，但观众投票名次较高	Bobby Bones, Bristol Palin
S2	遗珠指数 (Robbed Score): 评审认为好，但观众投票名次较低	Chandler Kinney, Mya

其中， S_1 的计算方法为：

$$S_1 = \max(0, \bar{R}_{pct} - P_{pct}) \times (1 - \sigma_{norm}) \quad (26)$$

具体的变量计算方法如下：

表 8: 计算方法

变量	定义	计算方法
$\bar{R}_{pct}$	平均评审排名百分位	$\frac{\bar{R}_{judge}-1}{N-1}$
P_{pct}	最终名次百分位	$\frac{P_{final}-1}{N-1}$
σ_{norm}	归一化的每周评委排名标准差	$\frac{\sigma_{rank}}{N-1}$
N	赛季参赛人数	-

$\bar{R}_{pct} - P_{pct}$ 它衡量了当选手最终排名比评委给出的排名更好时，排名的偏离程度。系数 $1 - \sigma_{norm}$ 衡量了表现的变化程度。当选手每周表现稳定地不好时，系数的值就较大，最后的争议也就越大。

S_2 的计算方法为：

$$S_2 = \max(0, Z_{last}) \times \max(0.5, 1 + \bar{Z}_{season}) \quad (27)$$

其中的变量的计算方法如下：

表 9: S2 变量定义

变量	定义	计算方法
Z_{last}	最后一周的 Z-Score	$\frac{Score_{last} - \mu_{week}}{\sigma_{week}}$
$\bar{Z}_{season}$	赛季平均 Z-Score	$\frac{1}{W} \sum_{t=1}^W Z_t$

$\max(0, Z_{last})$ 衡量了选手被淘汰的那一周的标准化表现。当选手表现高于平均水平的时候被淘汰了, 就会引起争议。 $\max(0.5, 1 + \bar{Z}_{season})$ 衡量了选手的历史表现。如果被淘汰的选手一直以来的表现都很好, 那么他的淘汰也会带来争议。特别地, 如果选手夺冠, 那么 S_2 的值将强制设定为 0, 因为此时不存在“被冤枉出局”。

4.3.2 案例分析

应用上面提到的指标进行计算, 得到所有选手的争议性得分。




图 5: 争议象限图

可以看到除了 Billy Ray Cyrus, 题目中提到的其他的三位争议选手 S_1 得分都很高, 争议排名也很靠前。而 Billy Ray Cyrus 的排名约在前 10%。这些都说明了指标 S_1 的合理性。图中还标注了 S_2 得分最高的人。

为了判断使用不同的规则是否会影响最终结果, 我们进行模拟。基于 SMC 反演的人气参数, 进行 1000 次蒙特卡洛模拟, 得到平均最终排名。

对于初始使用 Percentage Rule 的高 S_1 选手:

表 10: 高 S1 选手在不同规则下的表现

选手	S1	Outcome(Pct)	New Outcome (Rank)	差值
Bobby Bones	0.500	1.9	2.8	+0.9
Bristol Palin	0.263	4.7	5.8	+1.1
Billy Ray Cyrus	0.141	5.5	6.2	+0.7

对于这些选手，采用 Rank Rule 后，他们的排名都有所下降。这些选手本身的表现十分依赖粉丝投票，当粉丝的影响被 Rank Rule 限制后，他们的表现就变差了。

对于初始使用 Rank Rule 的高 S_1 选手：

表 11: 初始使用 Rank Rule 的高 S1 选手

选手	S1	Outcome(Rank)	New Outcome (Pct)	差值
Jerry Rice	0.299	3.1	2.6	-0.5

Jerry Rice 本身的人气就很高，在切换到 Percentage Rule 后反而能增强粉丝的影响，使得最终排名更高。

进一步对 S1 排名前 10% 的选手进行分析，Rank Rule 的平均排名比 Percentage Rule 高 0.16，且在 33.0% 的情况下排名更好 (Pct 仅 22.5%)。使用 Percentage Rule 并不能显著提升选手的排名，这可能是因为 S1 排名前 10% 的人并不都是超级巨星。他们的粉丝投票量并不都能对最后的结果产生显著影响。

我们还根据 S2 找出了两位评委分高但是最后淘汰了的争议选手。Chandler Kinney 全赛季表现统治级，却止步季军。而 Mya 是公认的技术完美者，却输给了 Donny Osmond。

表 12: 高 S2 选手分析

案例选手	赛季	S2 得分	指标排位	原本 Rule	使用新 Rule 后的排名变化
Chandler Kinney	S33	3.869	#1	Rank	+0.5
Mya	S9	3.373	#2	Percentage	+0

可以看到，使用新规则后，Chandler Kinney 的结果更差。这是因为她技术分优势被稀释，而粉丝分劣势被放大。而 Mya 的结果则没有什么变化，这可能是因为 Mya 在技术和粉丝基础上更加平衡。进一步通过对 S2 排名前 10% 的选手进行分析，采用 Percentage Rule 时排名平均会下降 0.32。这类争议性选手更受规则的影响。

同时为了分析 Judge Save 是否会对结果产生影响，进行如下分析。

表 13: Judge Save 影响分析

选手	S1 or S2	Rank (No Save)	Rank (+ Judge Save)	排名变化
Jerry Rice	S1: 0.299	3.1	3.6	+0.5
Bobby Bones	S1: 0.500	2.8	2.3	-0.5
Chandler Kinney	S2: 3.869	6.2	6.2	0.0

对于这三个案例 Judge Save 的效果并不明显。通过对 S_1 、 S_2 排名前 10% 的选手进行分析可知 Judge Save 对 S_1 分数高的选手并不重要，他们由于粉丝量较大，进入 Bottom 2 的概率只有 5.8%。而对 S_2 分数高的选手十分重要，他们进入 Bottom 2 的概率为 28.4%。

4.4 规则推荐




图 6: 不同规则得分对比

一个好的规则应该综合考虑粉丝和评委的权重。使用以下的公式进行计算最优的方案:

$$\text{Score}(R) = w_{fan} \cdot \underbrace{\min(\text{Align}_{fan}(R), 0.75)}_{\text{Capped Fan Utility}} + w_{judge} \cdot \text{Align}_{judge}(R) \quad (28)$$

其中 w_{fan} 是 Align_{fan} 的权重, w_{judge} 是 Align_{judge} 的权重, $w_{judge} = 0.7 > w_{fan} = 0.3$ 表示作为一个舞蹈竞技节目, 专业性 (Meritocracy) 应当占据主导地位。同时设定 0.75 为阈值, 超过此阈值的极高数值 (如 Pct Rule 的 0.945) 通常意味着民粹溢出 (Populism Overflow), 不应获得额外的系统奖励。在《英国公司法》(Companies Act 2006, s.21)[1]

中就有一样的做法，且根据 George Tsebelis (2002) 也从理论上说明了这一值的合理性 [2]。

基于上面的指标公式进行计算，得到不同规则的得分。

表 14: 不同规则的最终评分

Rules	Score
Rank Rule (No Save)	0.782
Percentage Rule (No Save)	0.772
Rank Rule + Judge Save	0.785

Rank Rule + Judge Save 为最优方案，它更好地平衡了技术与人气。同时 Judge Save 使得评审可以“淘汰”或“拯救”边缘选手。这避免了一些极端情况的出现。

5. 任务三

5.1 问题分析

问题 1: 分析职业舞者 (Professional Partner) 对比赛结果的具体影响究竟有多大？他们是仅提供技术指导，还是直接带来了粉丝流量？

问题 2: 判断评审和粉丝看重的特征是否相同，不同的选手特征（如年龄、性别、职业）在两个评价体系中的权重是否一致。

这是一个观测数据下的因果推断 (Causal Inference on Observational Data) 与多级方差分解 (Multilevel Variance Decomposition) 问题。需要建立模型去解释观众评分与评委打分。

5.2 建模

为精确分离各解释变量的贡献，构建三轨混合效应模型 (Triple-Track Mixed-Effects Model, 3T-MEM)，该模型通过三条独立且平行的线性混合模型 (LMM) 轨道，对复杂数据集中的不同特征维度或变量分组进行建模，最终把轨道之间的信息融合，使参数估计和数据分析更精准。

5.2.1 变量定义

在三轨混合效应模型 (Triple-Track Mixed-Effects Model, 3T-MEM) 中，轨道 A 对应评审评价部分。轨道 A 的因变量为 $Y_{i,t}^J = Z\text{-Score}(\text{Score}_{i,t})$ 。轨道 B 对应粉丝评价部分。该轨道的因变量为 $Y_{i,t}^F = \text{logit}(\hat{\pi}_{i,t})$ 。

选手特征 X_{Traits} 包括定义标准化后的选手年龄为 X_{Age} ，定义选手所属行业的分类变量为 $X_{Industry}$ ，定义比赛周次为 X_{Week} 。为了捕捉“搭档是谁”这一因素带来的长期、特殊影响，选取职业舞者随机截距 u_{Pro} 为处理同一选手多次观测数据之间的自相关性，选取选手个体随机截距 u_{Star} 。

图: 3T-MEM 流程图 (占位符)

(Placeholder for workflow diagram)

图 7: 三轨混合效应模型 (3T-MEM) 流程图 (占位)

5.2.2 模型构建

针对轨道 A，为了剖析评审的打分逻辑并检验是否纯粹基于技术表现，构建精英主义模型 (The Meritocracy Model)，具体计算公式如下：

$$Y_{i,t}^J = \beta^J \cdot X_{Traits} + u_{Pro}^J + u_{Star}^J + \epsilon \quad (29)$$

针对轨道 B1，为了剖析粉丝的总体投票逻辑，反映粉丝对选手的整体喜爱程度，包含舞技和个体魅力，构建粉丝总效应模型 (The Fan Popularity Model)，具体计算公式如下：

$$Y_{i,t}^F = \beta^{F1} \cdot X_{Traits} + u_{Pro}^{F1} + u_{Star}^{F1} + \epsilon \quad (30)$$

针对轨道 B2，为了剖析剔除技术表现后的粉丝纯偏好。我们创新性地在回归方程中引入了当周评审分 Y^J 作为控制变量，从而剥离出纯粹的人气偏差。构建粉丝净偏好模型 (The Fan Bias Model)，具体计算公式如下：

$$Y_{i,t}^F = \gamma \cdot Y_{i,t}^J + \beta^{F2} \cdot X_{Traits} + u_{Pro}^{F2} + u_{Star}^{F2} + \epsilon \quad (31)$$

其中，系数 β^{F2} 变成纯粹的眼缘或者同情分，不再包含因为跳得好所以得票高的部分。

5.2.3 模型诊断：多重共线性检验 (Model Diagnostics: VIF Check)

为了确保各解释变量之间独立，我们计算了方差膨胀因子 (VIF, Variance Inflation Factor)。计算公式如下：

$$VIF_j = \frac{1}{1 - R_j^2} \quad (32)$$

其中 R_j^2 是将第 j 个变量作为因变量，其余变量作为自变量进行辅助回归得到的决定系数。

变量 (Variable)	VIF 值	结论 (Conclusion)
Judge Score Z	1.27	无多重共线性 ($\ll 5$)
Age (Standardized)	1.44	无多重共线性 ($\ll 5$)
Industry (Avg)	~ 1.10	无多重共线性 ($\ll 5$)

所有变量的 VIF 均远小于警戒值 5，解释变量之间不存在多重共线性。

为了回答“职业舞者对结果影响有多大”，使用数值算法求解模型的参数，从而计算了组内相关系数 (ICC, Intraclass Correlation Coefficient)。ICC 值反映了了“职业舞者”这一变量解释了总方差的比例。其数学定义如下：

$$ICC_{Pro} = \frac{\sigma_{Pro}^2}{\sigma_{Pro}^2 + \sigma_{Star}^2 + \sigma_{\epsilon}^2} \quad (33)$$

其中 σ_{Pro}^2 为职业舞者随机效应的方差，分母为总残差方差（包括明星个体差异 σ_{Star}^2 和 σ_{ϵ}^2 ）。

表 15: 职业舞者方差贡献率 (Pro ICC) 分解

模型轨道	因变量	Pro ICC (ρ_{Pro})
Track A (Judge)	评审打分	< 0.001 (Negligible)
Track B1 (Fan Total)	粉丝总票	< 0.001 (Negligible)
Track B2 (Fan Bias)	净偏好	0.0029 (Low)

结论: 明星特质主导比赛，职业舞者作用被高估。

通过 3T-MEM 模型的方差分解，我们发现一职业舞者对比赛结果的直接统计解释力接近于零。说明 DWTS 本质上是一个依赖明星 (Star) 自身素质与观众缘的节目，而非职业舞者竞技。

5.3 结果分析：评价体系的异质性 (Heterogeneity)

为了回答评审和粉丝看重的特征是否相同，我们对比了轨道 A (Judge) 和轨道 B2 (Fan Bias) 的回归系数，发现了显著的结构性差异。

年龄：评审模型 (β_{Age}^J): 的系数-0.42，大于粉丝净偏好模型 (β_{Age}^{F2}): 系数为 -0.24。可以看到虽然双方都偏爱年轻人，但粉丝对高龄选手的容忍度显著高于评审。

行业：为了深入剖析不同背景选手的待遇差异，我们提取了所有行业的回归系数。我们将，计算系数差 $\Delta = \beta^{F2} - \beta^J$

$\Delta > 0$: 粉丝比评审更宽容（或评审过严）。

$\Delta < 0$: 粉丝比评审更苛刻（或评审过宽）。

我们挑选了九个行业进行分析。

行业 (Industry)	评审系数 β^J	粉丝净偏好 β^{F2}	民粹溢价 Δ
Politician	-1.05*	+0.13 (ns)	+1.18
Journalist	-1.11	-1.20	-0.09
Reality Star	+0.30	-1.01*	-1.31
Athlete	-0.17**	+0.02	+0.19
Musician	+0.34	-0.34	-0.68
TV Personality	-0.37***	-0.38***	-0.01
Model	-0.34**	-0.73***	-0.39
Comedian	-0.22	-0.64***	-0.42
Actor	0.00	0.00	0.00

注: *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$, . $p < 0.1$, ns 表示不显著。

由于数据量较大, P 值可以通过下式计算。

$$Z = \frac{\hat{\beta}}{SE(\hat{\beta})}, \quad p = 2(1 - \Phi(|Z|)) \quad (34)$$

可以看到相对于 Actor, TV Personality, Model, 的平均得分均显著小于 0, 他们的平均表现不如 Actor。这可能是因为 Actor 的技术相对更好。Athlete 仅在裁判这里显著差于 Actor 即使是运动员, 这可能是相较于粉丝, 裁判更在意运动员的技术, 而运动员在肢体表现力上也显著逊色于受过专业表演训练的演员。同时粉丝明显更偏好 Politician, 这可能和 Politician 的高影响力与一般的技术有关。评委则更偏好 Reality Star, Musician。

6 6. 任务 4

6.1 ACDW-B3 模型构建

基于前文的分析, 我们发现 DWTS 现有的两种评分规则无法平衡粉丝参与度与专业性。对此, 我们提出 ACDW-B3 系统, 使用前文构建的指标进行评判, 该系统的最后得分为 0.9053, 优于前文给出的最佳方案 Rank Rule + Judge Save (Score = 0.7827)。指标算法如下:

$$Score(R) = w_{fan} \cdot \min(Align_{fan}(R), 0.75) + w_{judge} \cdot Align_{judge}(R) \quad (35)$$

ACDW-B3 全称为 Adaptive Concave Diminishing-returns Weighted Bottom-3 System。它不是对旧规则的修补, 而是一套全新的动态共识机制。

Step A: 粉丝效用压缩 (Utility Compression)

针对 Percentage Rule 的粉丝投票的影响过大问题, 我们引入经济学中的边际效用递减思想。我们将粉丝的原始投票份额 $\pi_{i,t}$ 映射到非线性效用空间, 使得超级巨星的粉丝投票优势被相对限制, 更好地平衡专业性与粉丝参与度。

$$f_{i,t} = \frac{(\pi_{i,t})^p}{\sum_{k \in C_t} (\pi_{k,t})^p}, \quad p \in (0, 1) \quad (36)$$

其中参数 p (压缩因子): 控制压缩程度。我们设定 $p = 0.55$ 。

Step B: 动态共识权重 (Consensus-Driven Weighting)

为了解决“何时听专家, 何时听大众”的争议, 我们构建了共识度仪表盘 (Consensus Meter)。定义 ρ_t 为当周评审排名与粉丝投票排名的 Spearman 相关系数。评审权重 λ_t 随 ρ_t 动态调整:

$$\lambda_t = \lambda_{min} + (\lambda_{max} - \lambda_{min}) \cdot \frac{1 - \rho_t}{2} \quad (37)$$

高共识 ($\rho \approx 1$) 时, $\lambda_{min} = 0.6$ 。当大家都同意谁跳得好时, 让粉丝决定微小的排名差异 (Pro-Fan)。

高对抗 ($\rho < 0$) $\rightarrow \lambda \rightarrow \lambda_{max}$ (0.8): 评审与观众意见不同, 此时系统提升评审权重以防保证专业性。

Step C: 综合得分与 Bottom-3 机制

Bottom-3 危险区: 得分 $S_{i,t}$ 最低的 3 位选手进入危险区。相比传统的 Bottom-2, 扩大危险区增加了节目的悬念感 (Drama), 并给予了评审更大的裁量空间。

$$S_{i,t} = \lambda_t \cdot \frac{J_{i,t}}{\sum J} + (1 - \lambda_t) \cdot f_{i,t} \quad (38)$$

Judge Save 协议: 评审在 Bottom-3 中拥有最终裁决权, 必须淘汰技术分 (J) 最低的一位选手。

6.2 模型评判

对新的规则 R 计算指标, 与前文给出的最佳规则 Rank+Save 进行对比。

表 17: Multi-Dimensional Performance Comparison of Two Rules

Rule	Fan Align	Judge Align	Score
ACDW-B3	0.7630	0.9720	0.9053
Rank + Save	0.6570	0.8370	0.7827

可以看到 ACDW-B3 的综合得分突破了大幅增加。这主要归功于它惊人的 Judge Alignment (0.972) ——它几乎完美地执行了评审的专业意志, 仅在极少数关键时刻 ($Fans < 0.785$) 向即便如此也必须尊重的超级民意妥协。同时动态共识权重的引入, 规则可以在评委和粉丝意见高度不和的精彩时刻保持结果的公平性。

6.3 制作方建议 (Producer's Memo)

致: DWTS 节目制作委员会

建议在下个赛季引入 ACDW-B3, 它会带来收视率与专业口碑的双赢。

更刺激的直播体验: 动态共识权重可以在评委和粉丝意见不和的精彩时刻保证结果公平。现在节目可以更加追求戏剧性的冲突。

透明的公平: 粉丝会接受“50 万票和 55 万票差别不大”的边际递减逻辑, 只要规则是透明的。这比莫名其妙的“评委保送”更具公信力。

不需要改投票接口: 所有计算都在后台完成。观众依然正常投票, 感觉不到复杂的数学, 只感觉到“结果更合理了”。

7 灵敏度分析

在 4.4 中, 我们将 w_{judge} 设定为 0.7。如果我们将其增加或者减少 0.05, 结果如下:

w_{judge}	Rank Rule + Judge Save	Rank Rule	Percentage Rule
0.7	0.7885(best)	0.7822	0.7717
0.65	0.7808(best)	0.7754	0.7701
0.75	0.7963(best)	0.7890	0.7733

可见参数变化并不会影响最后给出的方案，参数设置是合理的。

参考文献

- [1] UK Parliament. *Companies Act 2006*, Section 21.
- [2] George Tsebelis. *Veto Players: How Political Institutions Work*. Princeton University Press, 2002.