

MCM_C

1.Introduction

1.1问题重述

在全球综艺娱乐市场中，竞技类真人秀融合专业性和观赏性，拥有广泛的观众基础。《与星共舞》作为这一领域的代表性节目，核心模式是专业舞者和名人搭档，源自英国节目《舞动奇迹》，在全球数十个国家播出，影响力遍布全球。该节目的评分体系由专家评审打分与粉丝投票两部分的融合结果决定每周的淘汰人选，需在竞技公平性与节目观赏性中进行权衡。

本研究以《与星共舞》美国版第 1-34 季的选手信息、评审分数及比赛结果等数据为基础，聚焦评分机制优化与影响因素量化两大核心目标，通过数学建模与数据分析完成以下任务：

任务1：构建数学模型估计每位选手各参赛周的粉丝投票数。解决模型一致性与估计确定性两大问题，需构建一致性衡量指标，并设计可量化的确定性度量指标。

任务2：结合估计的粉丝投票数，对比排名合并法和百分比合并法的应用效果，识别方法对粉丝投票的偏向程度。重点聚焦评审与粉丝存在分歧的争议性名人选手，分析采用两种合并方法是否会导致这些选手的比赛结果产生变化，同时探讨第28季改变的规则，让评审投票从倒数两对选手中选择淘汰对象，是否影响比赛结果。最后根据分析结果，进行多维度分析，选择推荐方法。

任务3：基于包含估计粉丝投票数的数据，构建模型分析专业舞者特征以及名人个体特征对比赛结果的影响。量化这些因素的影响程度差异，并对比它们对评审分数与粉丝投票的影响方式是否存在差异。

任务4：基于前述分析，设计一套兼具专业公平性和节目观赏性的投票评分合并系统，详细论证该系统的合理性，以说服节目制作方采纳该方法。

1.2文献综述

许多学者都曾研究过评分投票合并机制优化问题。Carlos Molinero*, Elsa Arcaute, Duncan Smith, Michael Batty通过分层聚类 and 空间网络分析得出单一合并方法可能会导致特定地区观众的声音被压制。Cynthia Dwork*, Moritz Hardt等作者进行相似性度量和公平约束优化，得出可以动态调整二者的合并权重的自适应权重机制。Amanda Aird, Cassidy All和其他作者研究双阶段合并机制，结合社会选择理论，构建多代理（Multi-Agent）的灵活架构。Alan Collins, Jordi McKenzie等作者通过构建计量经济学模型和统计分析，得出专业评审本身可能存在的“顺序偏差”的结论。

1.3 Our Work

2.Preparation for Modelling

2.1 Assumption and Justification

Assumption: 公众记忆的马尔可夫性，即当周的粉丝热度主要取决于上一周的热度保留和当周的表现，而不直接依赖于更久远的历史。

Justification: 社交媒体与节目播出节奏快，观众对选手的印象更新周期较短，常以周为单位。多数观众不会主动回顾所关注的选手几周前的表现，而是基于本期最新观感和上一周的记忆来决定本期是否关注该名选手和是否为其投票。

Assumption: 存在评审引导效应 (Judges' Influence)，评审的分数会对粉丝投票产生引导作用，具体表现为同情分、从众效应等现象。本文假设这种影响是以线性的叠加的形式纳入投票生成机制。

Justification: 该节目评审的专业点评及分数公布通常先于粉丝投票环节，会对粉丝投票产生引导。其次，采用线性叠加形式既能精准捕捉核心影响机制，又能兼顾模型的可解释性，避免过度复杂的非线性设定。

Assumption: 淘汰结果是唯一真值 (Elimination as Sole Ground Truth)，由于真实的粉丝票数从未公开，我们假设“被淘汰者必然是总分最低者（或最低之一）”是唯一的硬约束条件。

Justification: 从赛事运营逻辑来看，商业选秀节目需维持基本的规则公平性与观众信任度。为保障节目传播力和公信力，其淘汰机制本质上必须以选手综合表现所对应的量化得分为核心依据。

Assumption: 评委是理想的，即它们在决定淘汰哪个选手的时候只关心选手的技术。

Justification: 评委是专业人士，在评判的时候更多基于选手的表现，而非基于选手的人气等其他因素。

2.2数据预处理

我们对原始数据集进行了数据预处理，主要包括缺失值处理、特征编码及评分标准化。

2.2.1数据清洗与缺失值填充

原始数据在字段完整性和格式上存在一定差异，我们采取了以下处理策略：

缺失值处理：对于“选手年龄”字段，缺失值统一填充为中位数 30；“家乡国家”缺失时设为 "Unknown"；若“最终名次”缺失，则进行标记。

淘汰周逻辑解析：results 字段中提取关键信息。仅当包含 "Week X" 模式时判定为被淘汰；对于主动退赛 (Withdrew) 的情况，因其不属于比赛竞技结果，不计入淘汰事件。

评审分精简：针对数据中存在的 "N/A" 或 0 分情况（通常代表该周末参赛或评委缺席），我们设定仅保留大于 0 的有效分数。选手的每周得分由该周所有有效评审分的算术平均值决定。

2.2.2特征工程

我们对初始数据进行了热度编码与降维，以便模型计算。最终构建了一个 9 维特征向量。

年龄标准化：为消除量纲影响，对年龄进行标准化处理，计算公式为 $A_{\text{norm}} = (\text{Age} - 35) / 15$ 。

国籍二值化：根据选手是否来自美国，构造布尔特征 I_{US} （美国选手为 1.0，否则为 0.0）。

行业 One-Hot 编码：将选手的职业背景映射为演员、运动员、歌手、电视名人、模特、喜剧演员及其他共 7 个类别。这种编码方式能够有效捕捉不同行业背景对观众投票偏好的潜在影响。

2.2.3清洗后数据统计

经过清洗，最终获得包含34个赛季、共有421名选手的有效样本。数据集中记录了 298次淘汰事件，平均每赛季包含12.4名选手。

2.3Notation

4.任务二

关键假设 (Assumption of Weekly Independence): 除明确标注的双淘汰周与决赛夜外，选手的评审分数于每周竞赛结束后重置清零，消除历史分数对后续周分析的干扰。对于多周合并的特殊赛程，在正式分析前先对输入的评审分数与相关数据进行累加处理，确保数据维度与单周分析框架兼容。

4.1问题分析

估计的粉丝投票份额 $\hat{\pi}_{i,t}$ ，真实评审分 $J_{i,t}$ ，真实淘汰结果 E_t 是已知的，我们有以下三个目标。

目标 1: 比较 Rank Rule 与 Percentage Rule 的差异性

目标 2: 分析争议选手（如 Bobby Bones）在不同规则下的命运

目标 3: 推荐最佳规则组合

目标1和目标2要求我们分析实际不存在的情况，因而这是一个**概率性反事实推演 (Probabilistic Counterfactual Inference)**问题。

目标3要求我们推荐最佳的规则组合，需要建立量化指标进行判断。

4.2Rank Rule与Percentage Rule的比较

4.2.1新规则下的结果计算

任务二要比较新旧规则结果的差异，这就要求计算新的规则下的选手得票率。使用来自任务一中的后验粒子群进行计算。先使用这些粒子计算每周的选手得票率与生存分 π^k ，再运用新规则 R_{new} 计算选手生存分 S_{new}^k 与选手排名，最后得到新规则下的淘汰概率与淘汰结果。具体的计算方法与任务一中相同。

在新规则下，生存分最低的选手被淘汰。同时在新规则下选手 i 的淘汰率为：

$$P(i \in E | R_{new}) = \sum w^k \cdot 1(i \in E^k)$$

4.2.2规则比较

在得到新规则的结果后，就可以探究两种规则的结果之间的差异。使用结果一致率来衡量不同规则的淘汰结果的差异。一致率

$$P_t(E_{rank} = E_{pct}) = \sum_{k=1}^K w^k \cdot \mathbb{I}(E_{rank}^k = E_{pct}^k)$$

$$P(E_{RuleA} = E_{RuleB}) = \sum_{k=1}^K w^k \cdot \mathbb{I}(\text{Sim}(R_A, \pi^k) = \text{Sim}(R_B, \pi^k))$$

其次，我们计算翻盘概率，把在当年使用另外一种规则的条件下结果被改写的概率定义为反事实翻盘率

$$P(E_{new} \neq E_{real}) = \sum_{k=1}^K w^k \cdot \mathbb{I}(E_{new}^k \neq E_{real}^k),$$

把两种规则在相同输入下产生不同输出的概率定义为规则内秉背离度，计算公式如下：

$$P(E_{RuleA} \neq E_{RuleB}) = \sum_{k=1}^K w^{(k)} \cdot \mathbb{I}(\text{Sim}(R_A, \pi^{(k)}) \neq \text{Sim}(R_B, \pi^{(k)}))$$

接着，定义粉丝一致性得分，该值在取0时，代表规则淘汰了人气第1名，在取1时，代表规则淘汰了人气最后一名。计算公式如下：

$$\text{Alignment}_{Fan}(R) = \frac{\mathbb{E}_{k \leq K} [\text{Rank}_{\pi}(E^{(k)})] - 1}{n_t - 1}$$

其中，期望 $\mathbb{E}_{k \leq K}$ 表示对 K 个粒子的加权平均， $n_t - 1$

最后，计算评审一致性得分，该值数值越高，代表规则对技术分越友好，计算方法如下：

$$\text{Alignment}_{Judge}(R) = \frac{\mathbb{E}_{k \leq K} [\text{Rank}_J(E^{(k)})] - 1}{n_t - 1}$$

对Rank Rule和Percentage Rule的计算如下：

指标	Rank Rule	Pct Rule	胜者
Fan Alignment	0.687	0.945	Pct
Judge Alignment	0.823	0.781	Rank

基于上述实证数据，有以下关键结论：

规则内秉不一致性 (Inherent Rule Disagreement)： 我们的模拟显示，Rank Rule 与 Percentage Rule 在处理相同输入时，仅有 38.2%的全局一致率的概率产生相同的淘汰结果。

倾向性差异 (Bias Directionality)： Percentage Rule 具有显著的亲粉丝倾向 (Pro-Fan Bias)：其 Align_{Fan} 高达 0.945，比 Rank Rule (0.687) 高出0.38。这是因为百分比制允许超级巨星的海量票仓直接“淹没”技术分的劣势。Rank Rule 具有更高的技术权重 (Pro-Meritocracy)：其 Align_{Judge} 为

0.823，比 Pct Rule (0.781) 高出 5%。序数排名设置了粉丝投票的影响的上限，使得技术分落后的选手更容易跌入危险区。

同时我们在不同的季上计算了全局一致率，发现不同季的一致性有着明显差别：

S1-S2 (Rank Era)：全局一致率高达 73.2% (选手分化不明显，规则差异被掩盖)。

S3-S27 (Percentage Era)：全局一致率骤降至 28.5%。这说明该时期的赛制极度偏向粉丝，导致了大量不符合 Rank 逻辑的“爆冷”结果。

S28+ (Modern Era)：全局一致率回升至 66.4%。引入 Judge Save 后，赛制重新在技术与人气之间找到了平衡。

4.3 争议分析

4.3.1 指标构建

为了量化什么样的选手的有争议的，需要构建对应的指标。指标需要能够反映"评审意见"与"观众投票"之间的分歧。分歧具体体现在两种情况，分别是评委分高但是被早早淘汰以及评委分低但是走的很远。

构建以下两个指标来衡量两种情况是否发生：

维度	名称	捕捉的争议类型	典型案例
S_1	民粹指数 (Populist Score)	评审认为差，但观众投票保他走很远	Bobby Bones, Bristol Palin
S_2	遗珠指数 (Robbed Score)	评审认为好，但观众投票让他早走	Chandler Kinney, Mya

S_1 的计算方法为

$$S_1 = \max \left(0, \bar{R}_{pct} - P_{pct} \right) \times \left(1 - \sigma_{norm} \right)$$

具体的变量计算方法如下：

变量	定义	计算方法
$\bar{R}_{pct}$	平均评审排名百分位	$\frac{\bar{R}_{judge} - 1}{N - 1}$
P_{pct}	最终名次百分位	$\frac{P_{final} - 1}{N - 1}$
σ_{norm}	归一化的每周评委排名标准差	$\frac{\sigma_{rank}}{N - 1}$
N	赛季参赛人数	—

$\bar{R}_{pct} - P_{pct}$ 它衡量了当选手最终排名比评委给出的排名更好时，排名的偏离程度。系数 $1 - \sigma_{norm}$ 衡量了表现的变化程度。当选手每周表现都不好时，系数的值就较大，最后的争议也就越大。

S_2 的计算方法为

$$S_2 = \max(0, Z_{last}) \times \max(0.5, 1 + \bar{Z}_{season})$$

其中的变量的计算方法如下：

变量	定义	计算方法
Z_{last}	最后一周的 Z-Score	$\frac{Score_{last} - \mu_{week}}{\sigma_{week}}$
$\bar{Z}_{season}$	赛季平均 Z-Score	$\frac{1}{W} \sum_{t=1}^W Z_t$

$\max(0, Z_{last})$ 衡量了选手被淘汰的那一周的标准化表现。当选手表现高于平均水平的时候被淘汰了，就会引起争议。 $\max(0.5, 1 + \bar{Z}_{season})$ 衡量了选手的历史表现。如果被淘汰的选手一直以来的表现都很好，那么他的淘汰也会带来争议。特别地，如果选手夺冠，那么 S_2 的值将强制设定为0，因为此时不存在"被冤枉出局"。

待续

4.4规则选择

修正后的核心假设 (The Capping Hypothesis)

4.6指标构建与方案推荐

4.6.1指标构建

我们从三个维度判断一个方案的好坏。

维度	度量指标	含义
公平性	$Alignment Judge$	技术功底获得奖励

参与度	Alignment $_{Fan}$	观众投票有意义
-----	--------------------	---------

这两个指标不能同时满足，需要进行取舍。使用以下的公式进行计算最优的方案

$$\text{Score}(R) = w_{fan} \cdot \underbrace{\min(\text{Align}_{Fan}(R), 0.75)}_{\text{Capped Fan Utility}} + w_{judge} \cdot \text{Align}_{Judge}(R)$$

其中 w_{Fan} 是 Align_{Fan} 的权重。 w_{judge} 是 Align_{Judge} 的权重， $w_{judge} = 0.7 > w_{fan} = 0.3$ 表示作为一个舞蹈竞技节目，专业性 (Meritocracy) 应当占据主导地位。


Cap = 0.75: 设定 75% 的粉丝满意度为"饱和点"。超过此阈值的极高数值（如 Pct Rule 的 0.945）通常意味着**民粹溢出 (Populism Overflow)**，不应获得额外的系统奖励。设定Cap=0.75并非武断，而是基于比较制度分析的结构性边界。在《英国公司法》(Companies Act 2006, s.21) 中，**75%** 是通过"特别决议 (Special Resolution)"的门槛。这意味着持有 25% 以上股份的少数派构成 **"阻止性少数" (Blocking Minority)**，拥有对修改公司章程等重大事项的否决权。根据 George Tsebelis (2002) 的否决玩家理论，这一阈值实际上在制度中定义了一个事实上的否决玩家 (de facto veto player)：当我们在模型中将效用封顶在 0.75 时，本质上是在模拟一个保留了评委（25%）否决权的制度环境——这种设置确保了评委拥有对'比赛性质变更'的否决权，即便面对极端的粉丝单边主义，比赛的混合赛制架构 (Mixed Attributes) 也不会被篡改为纯人气选举，从而实现了系统级的制衡。

Tsebelis, George (2002). *Veto Players: How Political Institutions Work*. Princeton University Press.
UK Companies Act 2006 (Section 21)

4.6.1方案选择

基于上面的指标公式进行计算，我们最终确认 **Rank Rule + Judge Save** 为最优方案。

规则方案	Score
1. Rank Rule (No Save)	0.7822
2. Percentage Rule (No Save)	0.7717
3. Rank Rule + Judge Save	0.7855



Rank Rule比Percentage Rule更好。

- **基准方案：Rank Rule (No Save)**
 - **表现评价：**表现稳健，但缺乏亮点。
 - **局限性：**由于没有纠错机制，模型只能反映基础排名的线性结果，导致上限受限（Ceiling Effect），无法处理极端偏差情况。
- **落后方案：Percentage Rule (No Save)**
 - **表现评价：**整体表现最弱，主要指标（0.7717）甚至低于基础的 Rank Rule。
 - **失分原因：**该规则受到严格的数学限制。公式中的“封顶”（Cap at 0.75）限制了高分段的溢出收益，同时专业分（Judge Score）的权重未能有效拉高均值，导致虽然粉丝分极高，但整体被严重拖后腿。

1. 为什么不选 Pct Rule?

- Pct Rule 虽然 Fan Alignment 最高（0.945），但它**过度倾向粉丝**。
- 超级巨星（如 Bobby Bones）可以凭借海量票仓**淹没**技术分劣势。
- Judge Alignment 仅 0.781，意味着技术功底无法获得应有的奖励。
- **问题：**评审专家沦为"橡皮图章"，比赛失去公信力。